

Dale a tu IA un buen punto de partida.

Qué aprendimos midiendo nuestro propio trabajo con IA

Cómo trabajamos hoy

Un prompt. Una respuesta. A ver qué sale.

- Abrimos el chat, escribimos lo que queremos y copiamos lo que devuelve.
- Sin plan escrito, sin registro de lo decidido, sin comprobar si hizo lo que pedimos.
- Funciona sorprendentemente bien... hasta que deja de funcionar.

“A ver qué sale”

Qué sale mal

Se inventa cosas

Rellena huecos con algo verosímil.

Se desvía del objetivo

Resuelve otra cosa parecida.

No se puede comprobar

Lo aceptamos o lo rehacemos entero.

Hay que rehacerlo

Y volvemos a empezar.

El que más caro sale es el tercero.

¿Y si el problema no es el modelo, sino el sitio donde lo ponemos a trabajar?

- Le pedimos que trabaje en una carpeta que no conoce.
- Sin reglas escritas y sin manera de verificar nada.
- A una persona nueva tampoco le saldría bien.

Qué es un entorno preparado

1

La carpeta ordenada

Los materiales donde se esperan.

2

Las reglas escritas

Lo que damos por acordado, escrito.

3

Las comprobaciones listas

Comprobar sin leerlo y confiar.



Tres cosas, ninguna exótica. Aquí, la pantalla donde se escribe qué se quiere lograr: eso es “las reglas escritas”.

Contexto y RAG

Buscar la frase exacta y decir en qué archivo y en qué línea está, en vez de entregar todo el archivo.

EL PROBLEMA

Darle un repositorio entero a un modelo es como darle una biblioteca y pedirle una cita.

EL EJEMPLO

«¿En qué rango asigna Kubernetes un NodePort?» La respuesta buena no es el documento: es «30000-32767, en service.md».

Escribir qué tiene que pasar, antes

EL PROBLEMA

Si no dijimos qué esperábamos, cualquier resultado parece aceptable.

EL EJEMPLO

«Al terminar el asistente, los dos botones se pueden pulsar» se puede comprobar. «Mejorar la interfaz» no.

Escribir qué tiene que ocurrir antes de hacerlo, para poder comprobarlo después.

El programa alrededor del modelo

El programa que lo rodea: qué puede ejecutar, hasta dónde llega y qué recuerda.

EL PROBLEMA

El modelo solo habla. Alguien tiene que darle herramientas, límites y memoria.

EL EJEMPLO

El nuestro abre la aplicación de verdad, recorre las pantallas y mide dónde cae cada clic.

Piensa, actúa, comprueba

EL PROBLEMA

Un solo intento rara vez acierta, y repetir sin comprobar es dar vueltas.

EL EJEMPLO

El nuestro para cuando la comprobación pasa, no cuando el agente cree que terminó.

El ciclo que repite. Y, sobre todo, quién decide cuándo parar.

Alguien que intenta romperlo

Alguien que intenta romperlo, no confirmarlo. Y que no participó en hacerlo.

EL PROBLEMA

Pedirle a alguien que confirme que está bien casi siempre devuelve «está bien».

EL EJEMPLO

Una revisión encontró en nuestra documentación un texto que afirmaba una cosa mientras la captura de al lado la desmentía. Llevaba semanas publicado.

Lo que se anota en vez de olvidarse

EL PROBLEMA

«Esto luego lo arreglo» no sobrevive a la semana.

EL EJEMPLO

Midiendo encontramos un defecto del empaquetador que no tocaba arreglar ahí. No se arregló de pasada: se anotó.

Lo que se deja escrito y con dueño, en vez de olvidado.

Capacidades y enchufes

Las skills son formas de trabajar que el agente aprende y reutiliza; MCP es el enchufe a herramientas de verdad.

EL PROBLEMA

Un modelo sin herramientas solo puede escribir texto sobre el trabajo, no hacerlo.

EL EJEMPLO

Con eso, el agente no describe la aplicación: la abre, la recorre y mide.

La tarea con un prompt suelto

«...el gate de Definition of Ready rechaza issues escritos en español correcto: frases como “El rollback conserva el historial”... Arréglalo.»

8 min 44 s

de reloj

2

archivos

111 / 14

líneas +/-

19 / 19

marcadores

- Escribió pruebas por su cuenta, aunque nadie se lo pidió.
- 33 de 34 frases legítimas pasan, y los 19 marcadores de verdad siguen rechazados.

La misma tarea con el flujo

Petición → issue → preparación → change → tareas → evidencia → revisión → deuda → archivo

31 min 3 s

de reloj

28

archivos

1822 / 4

líneas +/-

18 / 19

marcadores

- Con issue, spec, medición repetible y assessment de deuda.
- 34 de 34 frases legítimas, y 18 de 19 marcadores.

Qué salió distinto

	Prompt suelto	Flujo completo	Sin arreglar
Frases correctas que pasan	33 de 34	34 de 34	2 de 34
Marcadores de verdad rechazados	19 de 19	18 de 19	16 de 19
Tiempo	8 min	31 min	—
Archivos tocados	2	28	—

Ninguna de las dos lo resolvió del todo, y fallan en cosas distintas.

Las dos encontraron, sin que nadie se lo pidiera, un fallo que nadie había visto: la búsqueda de palabras no reconoce la «í» acentuada.

Qué medimos

Diez preguntas con respuesta conocida sobre 6812 bytes de notas, PDF y Word.

Método	Devolvió la respuesta
Abrir todo el corpus	8 de 10
Buscar literal, grep	8 de 10
Contexto preparado	10 de 10

Aquí ganamos.

Dos preguntas más, y además decimos en qué página y párrafo está la respuesta.

Pero este corpus cabe en un correo electrónico.

0 de 20

Sobre kubernetes/website y python/cpython, con veinte preguntas congeladas antes de medir.

Abrir todo el corpus **20 de 20**

Buscar literal, grep **20 de 20**

Contexto preparado **0 de 20**

La causa está medida: indexó 45 de 2654 fuentes en Kubernetes y 42 de 2753 en CPython, y se quedó sin presupuesto.

Lo medimos otra vez cuatro días antes de esta charla, con la versión publicada de hoy: sigue en 0 de 20.

Está publicado en nuestra página de evidencia, al lado del número bueno.

Tres cosas

1 El número bueno no predecía nada.

Si solo hubiéramos medido en el corpus pequeño, estaríamos vendiendo algo que no funciona donde importa.

2 Comprobar de verdad cambia el resultado.

Un arnés certificó nuestra aplicación con cero hallazgos. Su versión corregida encontró 66 problemas distintos sobre la misma aplicación, repetidos en 23 combinaciones: 360 renglones. Entre ellos, siete controles que no se podían pulsar.

3 La revisión adversarial funciona cuando duele.

Encuentra lo que llevamos semanas mirando sin ver, y justo donde más incómodo resulta.

Lo que estoy proponiendo

No vengo a venderos una solución terminada.



Companion 0.3.2, commit d744c47

Lo que hay

Una aplicación para Windows, un núcleo que hace lo mismo desde la terminal, y una página donde publicamos lo que medimos.

Comprobado

Los seis pasos documentados para empezar funcionan de principio a fin. El diagnóstico de un proyecto nuevo: 29 comprobaciones, ningún fallo.

Lo que falta

La recuperación en repositorios grandes no funciona. Está medido y publicado.

Por qué lo abro

El objetivo no es tener un producto: es que preparar el entorno se note de verdad en el trabajo de cualquiera que use IA.

Prepara el entorno antes de pedirle nada al modelo.

- 1 Escribid qué esperáis antes de pedirlo. Si no, cualquier resultado parece bueno.
- 2 Poned una comprobación que pueda fallar. Una que nunca falla no está comprobando nada.
- 3 Medid vuestro propio trabajo y publicad lo que salga. Nosotros salimos 0 de 20 y lo contamos aquí.

Y una cuarta, si os apetece: venid a construirlo. Es abierto y está a medias.

Qué no medimos

Y por lo tanto, qué no afirmamos.

Consumo de tokens

No se midió, y no se estima a partir de bytes.

Alucinaciones

El método no las observa.

Ahorro de tiempo o dinero

No hay ninguno demostrado.

Calidad de respuesta

Evaluarla con el mismo agente que la produjo sería juez y parte.

Comparación con otros productos

No se hizo.

La comparación de las dos vías

Mide una tarea, y nada más. Además, las dos partían con la misma información previa sobre el defecto.

De dónde sale cada cifra

Ninguna cifra de esta charla se escribió de memoria. Cada una sale de un registro de este repositorio.

Diapositiva	Registro
6, 17 · las veinte preguntas y su resultado	run-02/kubernetes-website.json y cpython.json
13, 14, 15 · las dos vías, sus tiempos y sus cifras	flow-comparison/evaluation.json, timing.json, resultado.md
16 · el microcorpus	docs/companion/EVIDENCE.md
18 · el contraste del arnés	after/harness-contrast.json y harness-contrast-detail.json
19 · capturas y arranque documentado	docs/companion/SCREENSHOTS.md, after/documentated-start.json

Si una cifra no está en esta tabla, no está en una diapositiva.